固定 Skill 在 ALFWorld 中的复现边界

DeepSeek-v4-flash 的分阶段实验与 v8 确认结果

技术摘要

v8 没有复现 v7 定向测试中的效率优势。20 道与开发集不重叠的 valid_seen 任务、3 个条件、3 次重复共 180 个 episode 中，No Skill 与 Oracle v7 均为 60/60；Oracle v7 的平均 Total Tokens 高 33.3%，端到端延迟高 16.5%，单次成功成本高 15.0%。

配对 bootstrap 的成本区间均跨过 0，不能据此断言 Skill 必然增加成本。可以确认的是，v8 不支持“v7 在保持成功率的同时稳定降低推理开销”这一说法。聚合结果上，No Skill 在质量相同的情况下占用更少 token、时间和成本。

逐任务差异很大。Oracle v7 在 23/60 个配对 episode 中减少 Total Tokens，在 37/60 个中增加；差值中位数只有 +2,413，均值却是 +15,358。少数超长轨迹控制了均值，因此后续研究必须同时报告均值、中位数、任务级区间和逐题轨迹。

1. 证据链与确认问题

本项目先在 Mini Lab 验证 Agent、工具调用和自动评分，再进入 ALFWorld。v5 检验初版固定 Skill 与检索方法；v7 根据开发集暴露的目标绑定与动作语义问题改写两个 Oracle Skill；v8 用未参与开发的任务检查这一改写能否复现。所有成功标签都来自 ALFWorld 的 won 字段，模型不参与评分。

阶段	数据角色	规模	主要结论
v5 正式实验	独立测试	30 题×5 条件×3 次	初版 Skill 无稳定收益；All Skills 成本高
v7 定向测试	窄范围独立测试	10 题×3 条件×3 次	v7 出现质量与成本同时改善的信号
v8 确认实验	任务不重叠确认集	20 题×3 条件×3 次	成功率持平，效率优势未复现

表 1 三阶段数据用途。v8 与开发任务不重叠，但仍属于 valid_seen。

2. v8 的六项核心指标

条件	成功	成功率	Input	Output	Total	延迟(s)	成本/成功
No Skill	60/60	100.00%	45,035	1,135	46,170	24.60	$0.000738
Oracle v5	59/60	98.33%	56,942	1,451	58,393	28.93	$0.000919
Oracle v7	60/60	100.00%	60,337	1,191	61,528	28.67	$0.000848

表 2 v8 总体结果。每个条件 60 个 episode；成本包含失败 episode 的消耗。

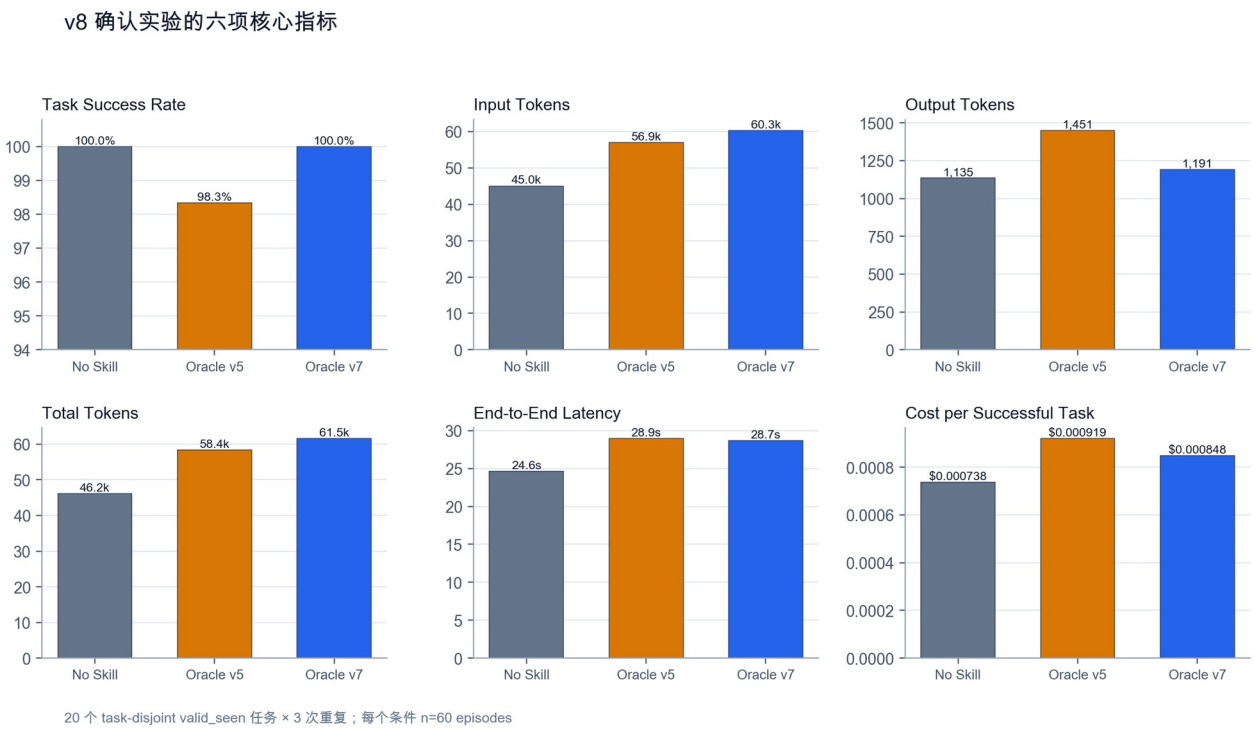


图 1 Task Success Rate、Input Tokens、Output Tokens、Total Tokens、End-to-End Latency 与 Cost per Successful Task。

Oracle v7 相对 No Skill：Input Tokens +34.0%，Output Tokens +5.0%，Total Tokens +33.3%，延迟 +16.5%，单次成功成本 +14.9%。两者成功率相同。

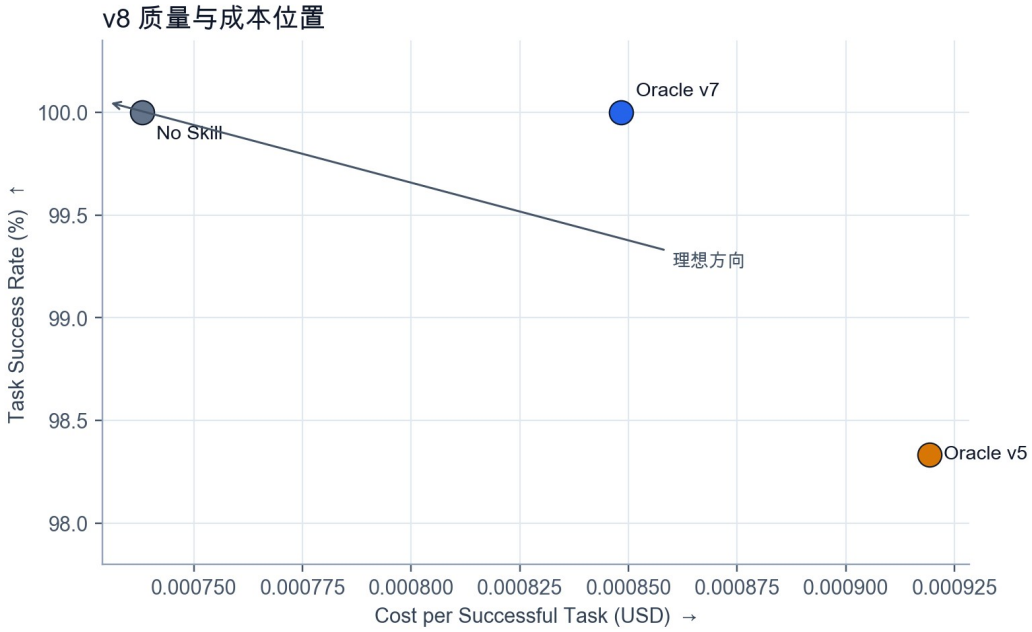


图 2 v8 的质量与成本位置。No Skill 与 Oracle v7 同为 100%，No Skill 成本更低。

3. 配对统计没有支持稳定优势

相对 No Skill	成功率差(pp)	成功率差 95% CI	p	Total 差	Total 差 95% CI	延迟差(s)	单集成本差
Oracle v5	-1.67	-5.00 至 0.00	0.717	+12,223	-3,979 至 29,692	+4.32	+0.000166
Oracle v7	+0.00	0.00 至 0.00	1.000	+15,358	-18,278 至 46,718	+4.06	+0.000110

表 3 按任务成组、保留三次重复的配对 bootstrap，20,000 次重采样。

Oracle v7 的成功率差为 0，区间也是 0，这是两组都达到 60/60 的结果，不代表两种方法等价。Total Tokens、延迟和单个 episode 成本的 95% 区间都跨过 0。样本只有 20 道任务，轨迹长度又高度偏斜，区间较宽。

指标	均值差	中位数差	v7 更低/相同/更高
Input Tokens	15,302.0	2,419.0	23/0/37
Output Tokens	56.2	-15.5	32/2/26
Total Tokens	15,358.2	2,413.0	23/0/37
Latency (ms)	4,062.2	-271.0	31/0/29
Cost (USD)	0.000110	0.000026	26/0/34
Tool Calls	3.0	0.0	29/11/20

表 4 Oracle v7 减 No Skill 的 episode 级配对差。负值表示 v7 更省。

延迟的均值差为 +4.06 秒，中位数却是 -0.27 秒；Total Tokens 的均值差为 +15,358，中位数为 +2,413。均值和中位数方向或幅度不同，说明结论受长尾轨迹影响。

4. 成本差异集中在少数任务

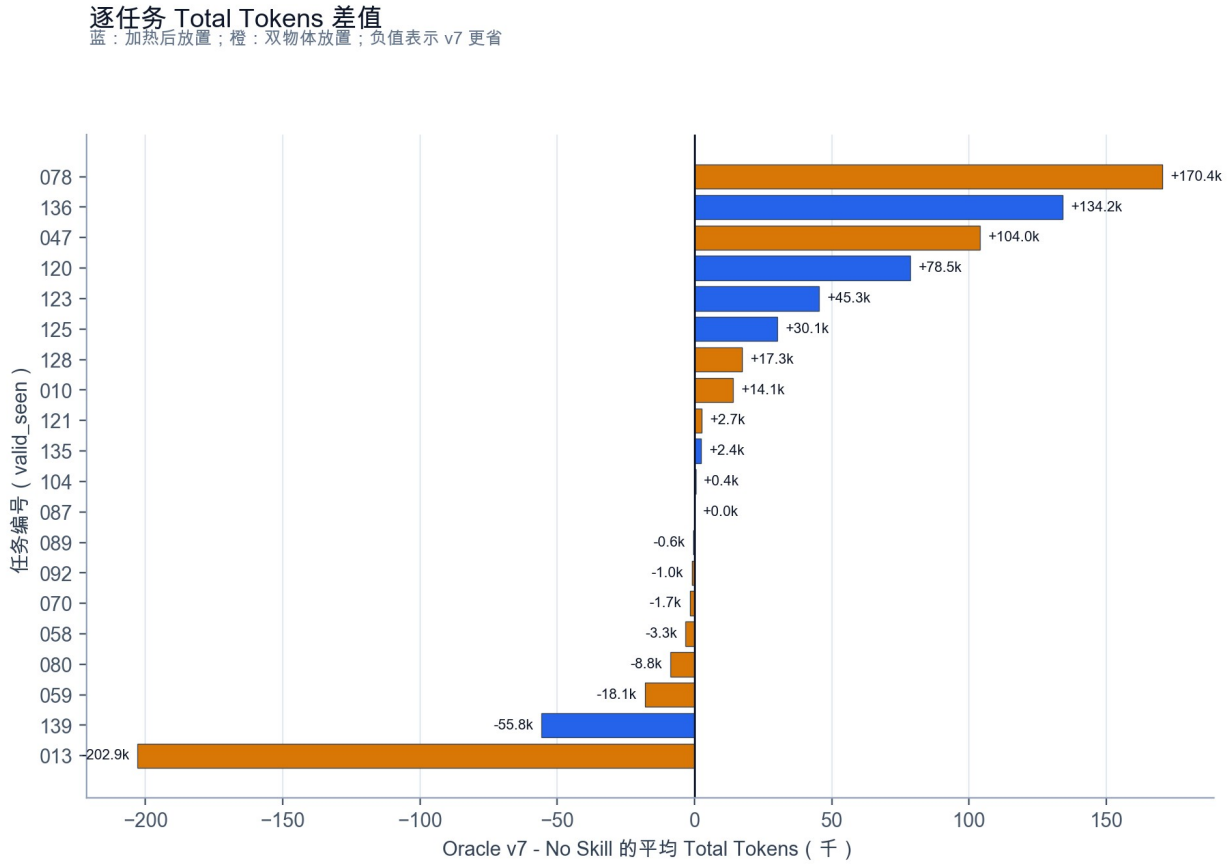


图 3 每道任务三次重复后的平均 Total Tokens 差。正值表示 Oracle v7 更贵。

任务	类别	Total 差	延迟差(s)	成本差
valid_seen:013	双物体	-202,850	-35.64	-0.001855
valid_seen:078	双物体	+170,386	+47.11	+0.001668
valid_seen:136	加热	+134,180	+32.72	+0.001146
valid_seen:047	双物体	+104,026	+24.89	+0.000892
valid_seen:120	加热	+78,513	+27.30	+0.000861

任务	类别	Total 差	延迟差(s)	成本差
valid_seen:139	加热	-55,790	-23.81	-0.000820
valid_seen:123	加热	+45,294	+13.54	+0.000490
valid_seen:125	加热	+30,086	+11.86	+0.000406

表 5 按 Total Tokens 绝对差排序的前 8 道任务。

v7 在任务 013 和 139 上大幅减少 token，但在 078、136、047、120 上明显增加。单一平均数会把这些相反方向压成一个值。固定 Skill 的作用更像任务相关的行为干预，而不是稳定的全局加速器。

5. 任务族分解显示加热 Skill 的成本问题

任务族	条件	成功	Input	Total	延迟(s)	成本/成功
加热后放置	No Skill	18/18	22,547	23,281	17.81	$0.000455
加热后放置	Oracle v5	18/18	25,508	26,256	18.46	$0.000476
加热后放置	Oracle v7	18/18	61,286	62,399	27.99	$0.000805
双物体放置	No Skill	42/42	54,673	55,979	27.52	$0.000859
双物体放置	Oracle v5	41/42	70,414	72,166	33.42	$0.001114
双物体放置	Oracle v7	42/42	59,930	61,155	28.96	$0.000867

表 6 任务族分解。加热类 18 episodes，双物体类 42 episodes。

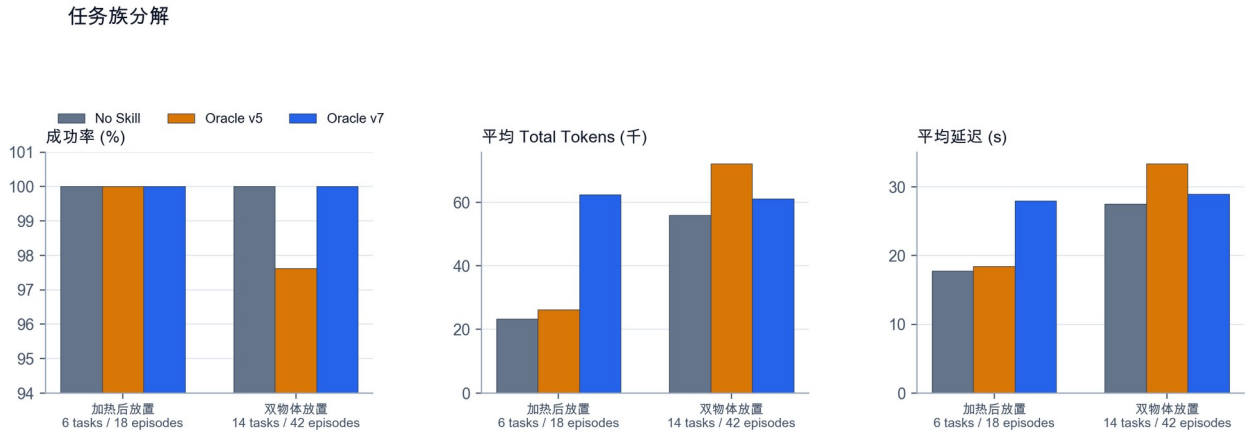


图 4 两类任务的成功率、Total Tokens 与延迟。

加热任务中三组均为 18/18，但 Oracle v7 的平均 Total Tokens 为 62,399，No Skill 为 23,281；延迟分别为 27.99 秒和 17.81 秒。双物体任务中 v7 与 No Skill 都是 42/42，成本接近。v8 的总体成本差主要来自加热任务和少数双物体长轨迹。

6. v7 信号没有跨任务集复现

测试集	episodes N/S	成功率 N/S	Total N/S	延迟 N/S	成本 N/S
v7 定向 valid_unseen	30 / 30	96.7% / 100.0%	36,191 / 31,913	18.65 / 15.41	$0.000710 / $0.000515
v8 确认 valid_seen	60 / 60	100.0% / 100.0%	46,170 / 61,528	24.60 / 28.67	$0.000738 / $0.000848

表 7 No Skill（N）与 Oracle v7（S）在两批独立任务上的方向变化。

v7 定向测试中，Oracle v7 为 30/30，No Skill 为 29/30，v7 的 Total Tokens 和成本更低。v8 中两者都为 60/60，成本方向反转。前一批结果不是伪造或程序错误，它是对特定任务集成立、对确认集没有复现的结果。

v5 的较宽任务覆盖也没有给出稳定 Skill 优势：All Skills 虽达到 98.89%，但相对 No Skill 只高 1.11 个百分点，成功率差区间覆盖 0；No Skill 的平均 Total Tokens 和单次成功成本最低。v5、v7、v8 合在一起支持的是异质性，而非统一增益。

7. 指标定义与实验规则

- Task Success Rate = 成功 episode 数 / episode 总数；成功由 ALFWorld 的 won=true 判定。
- Input Tokens 是全部模型调用输入 token 之和；Output Tokens 是全部输出 token 之和。
- Total Tokens = Input Tokens + Output Tokens。
- End-to-End Latency 覆盖路由、模型调用、环境交互和完成判定；报告中以秒表示。
- Cost per Successful Task = 条件内全部 episode 的模型成本 / 成功 episode 数，失败消耗计入分子。
- 同一道题、同一次重复在不同条件之间配对；bootstrap 以任务为抽样单位，保留任务内三次重复。

三个条件使用同一 DeepSeek-v4-flash、temperature=0、Agent 协议、任务顺序和最大步数。条件间只改变是否加载固定 Skill 以及 Skill 版本。冻结文件保存完整轨迹，不依赖模型自评。

8. 局限与当前结论

- v8 只有 20 道任务，并且只覆盖加热后放置与双物体放置；100% 成功率存在天花板效应。
- v8 与开发任务不重叠，但属于 valid_seen，不能当作新的 OOD 证据。
- 三次重复提高了对模型随机性的观察，不能替代更多独立任务；统计区间按任务成组计算。
- 结果只覆盖 DeepSeek-v4-flash 和当前文字交互协议，不能外推到其他模型、视觉环境或不同 Agent。

当前不应宣称固定 Skill 在 ALFWorld 上有效。更准确的表述是：人工 Skill 能在部分目标类型和任务实例上改变行为，但收益不稳定；过长或不匹配的 Procedure 会增加上下文与交互成本。Oracle 上界尚未形成可复现优势，因此现在扩展 Router 研究没有足够依据。

9. 下一步

- 冻结 v8，不再根据这 20 道确认题修改 Skill。把 v7 的正结果与 v8 的反转同时保留。
- 转向新的标准环境做小规模 Pilot，优先选择 ScienceWorld；先跑 No Skill 与人工 Oracle，确认 Oracle 上界后再比较检索器。
- 继续保留六项核心指标、任务级配对区间、中位数、逐题差异和失败轨迹。只有质量或成本出现可复现收益，才扩大实验规模。

数据与版本

运行 ID：alfworld-v8-confirm-20x3；冻结记录：180；任务数：20；每题重复 3 次。

冻结文件 SHA-256：210b2f05db7d85fa20210cda624677a37d2cb0059648aa4ae2079ebfb80cdecc。统计表、失败摘要和图件位于 results/formal_v8。v5 基线 No Skill 成功率为 97.78%。