固定 Skill 检索对语言模型 Agent 表现和成本的影响

ScienceWorld 发现实验和独立确认实验

摘要

本报告合并两批预先固定的 ScienceWorld 文字交互实验。发现实验收录在 ScienceWorld v9 正式实验报告中，包含 12 道任务、5 个条件和 3 次重复，共 180 个 episode。独立确认实验使用另外 12 道 test variation，只比较 No Skill、Flat Retrieval 和 Body-aware Retrieval，共 108 个 episode。成功标签全部来自环境分数，模型不能为自己评分。

发现实验中，Body-aware Retrieval 的成功率为 88.89%，No Skill 为 69.44%；成功率差为 19.44 个百分点，任务聚类 Bootstrap 95% 置信区间为 8.33 至 30.56 个百分点。Body-aware 的平均 Total Tokens 比 No Skill 低 67.19%。

独立确认实验中，Body-aware 与 Flat 的成功率均为 94.44%，No Skill 为 80.56%。Body-aware 相对 No Skill 高 13.89 个百分点，但成功率区间触及 0。其平均 Total Tokens 低 39.09%，任务级 Token 区间仍跨过 0。两批实验的点估计方向一致，但确认实验没有证明 Body-aware 的成功率稳定高于 Flat，也没有证明 Token 在多数任务上都会下降。

关键词　大语言模型 Agent　固定 Skill　Skill 检索　ScienceWorld　推理成本

一 研究问题和证据结构

研究关注两个问题。第一，人工固定的 Skill 能否提高交互任务成功率。第二，在成功率相近时，检索 Skill 正文是否比只检索名称和描述更节省推理开销。项目不训练 Router，不自动学习 Skill，也不使用 PPO。

发现实验用于识别信号，独立确认实验用于检验该方向能否在未使用的新 variation 上重复。两个实验使用相同的六类任务、Skill v3、Agent 协议和模型请求名称，但题目不重叠。

表 1　两批实验的设计

实验	内部运行编号	任务	条件	规模
发现实验 对外报告 v9	scienceworld-v6-router-formal-12x3	12 道新题 第 3 和第 4 个 test variation	5	180 episodes
独立确认实验 v10	scienceworld-v10-confirm-12x3	12 道新题 第 5 和第 6 个 test variation	3	108 episodes

二 实验方法

实验条件

表 2　五种条件的 Skill 加载方式

条件	加载内容	选择依据	用途

条件	加载内容	选择依据	用途
No Skill	不加载 Skill	无检索	普通 Agent 基线
All Skills	全部 6 个 Skill	不检索	完整上下文条件
Flat Retrieval	Top 3 Skill	Name 和 Description	轻量检索基线
Body-aware Retrieval	Top 3 Skill	完整五字段正文	正文感知检索
Oracle v3	人工 Gold Skill	任务类型映射	已知正确 Skill 的上界

独立确认实验只保留 No Skill、Flat Retrieval 和 Body-aware Retrieval。这样可以直接检验真实可部署条件，避免继续为 All Skills 和 Oracle 支付 API 成本。

运行协议

表 3　两批实验共同使用的运行设置

项目	固定设置
模型请求名称	deepseek-v4-flash
采样	temperature 0　thinking disabled
Agent 协议	scienceworld-v2　每轮最多执行一个环境动作
环境	ScienceWorld easy simplification　test split
动作上限	每个 episode 最多 400 个环境步
重复	每道题每个条件 3 次　条件顺序按固定种子打乱
成功条件	ScienceWorld 环境分数达到 100

六项核心指标为 Task Success Rate、Input Tokens、Output Tokens、Total Tokens、End-to-End Latency 和 Cost per Successful Task。成本按运行时记录的 Token 与实验代码中的价格表估算，用于条件间比较，不代表当前账单价格。

统计分析保持同一道题、同一次重复的配对关系。成功率和 Total Tokens 均以任务为重采样单位计算 20,000 次 Bootstrap 区间，并报告任务级精确符号检验。三次重复用于估计运行波动，不能当作三道独立任务。

三 实验结果

发现实验结果

表 4　ScienceWorld v9 报告中发现实验的六项核心指标

条件	成功率 %	Input Tokens	Output Tokens	Total Tokens	延迟 秒	每成功任务成本 USD
No Skill	69.44% ± 4.81	740,335 ± 375,985	3,557 ± 614	743,891 ± 376,227	73.83 ± 16.28	$0.007158 ± 0.001640

条件	成功率 %	Input Tokens	Output Tokens	Total Tokens	延迟 秒	每成功任务成本 USD
All Skills	91.67% ± 0.00	653,760 ± 515,605	3,681 ± 1,730	657,441 ± 517,209	62.10 ± 15.38	$0.004643 ± 0.002403
Flat Retrieval	75.00% ± 8.33	783,636 ± 426,332	3,219 ± 1,056	786,855 ± 427,382	71.04 ± 21.21	$0.006609 ± 0.003254
Body-aware Retrieval	88.89% ± 9.62	241,813 ± 100,926	2,273 ± 1,019	244,086 ± 101,516	40.45 ± 7.98	$0.002713 ± 0.001010
Oracle v3	94.44% ± 4.81	279,928 ± 118,033	2,289 ± 542	282,217 ± 118,563	42.92 ± 6.43	$0.002701 ± 0.000645

发现实验中，Body-aware 的成功率比 No Skill 高 19.44 个百分点。成功率区间完全高于 0，任务级符号检验 p=0.031。Body-aware 的平均 Total Tokens 低 67.19%，任务聚类 Token 区间也低于 0。Flat 的成功率只高 5.56 个百分点，平均 Total Tokens 反而增加 5.78%。

独立确认实验结果

表 5　ScienceWorld v10 独立确认实验的六项核心指标

条件	成功率 %	Input Tokens	Output Tokens	Total Tokens	延迟 秒	每成功任务成本 USD
No Skill	80.56% ± 4.81	460,745 ± 6,262	2,209 ± 41	462,953 ± 6,225	77.43 ± 7.76	$0.004256 ± 0.000221
Flat Retrieval	94.44% ± 4.81	300,464 ± 117,273	1,888 ± 336	302,352 ± 117,579	55.83 ± 16.84	$0.002704 ± 0.000743
Body-aware Retrieval	94.44% ± 4.81	280,219 ± 119,143	1,761 ± 211	281,980 ± 119,350	50.08 ± 13.76	$0.002551 ± 0.000700

确认实验中，Flat 和 Body-aware 均成功 34 次，No Skill 成功 29 次。两种检索条件都比基线高 13.89 个百分点。Body-aware 的平均 Total Tokens 比 No Skill 低 39.09%，延迟低 35.32%，每个成功任务成本低 40.06%。

Body-aware 与 Flat 的成功率相同。Body-aware 的平均 Total Tokens 比 Flat 低 6.74%，延迟低 10.31%，每个成功任务成本低 5.65%。这些是总体均值差，不表示每道题都有相同变化。

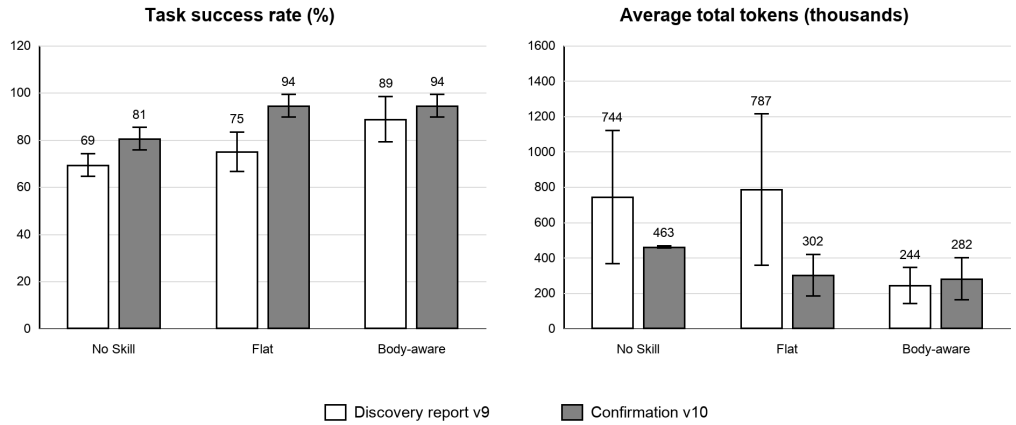


图 1　两批实验在三个共同条件上的成功率和 Total Tokens　误差线为三次重复间标准差

配对推断

表 6　检索条件相对 No Skill 的任务级配对结果

实验和方法	成功率差 百分点	成功率 95% CI	成功率 任务级 p	Total Tokens 变化	Token 差 95% CI 千 Tokens	Token 任务级 p
发现实验 对外报告 v9 Flat Retrieval	+5.56	[-5.56, 16.67]	0.625	+5.78%	[-651, 835]	0.774
发现实验 对外报告 v9 Body-aware Retrieval	+19.44	[8.33, 30.56]	0.031	-67.19%	[-1,199, -3]	0.146
独立确认实验 v10 Flat Retrieval	+13.89	[0.00, 33.33]	0.250	-34.69%	[-478, 31]	0.774
独立确认实验 v10 Body-aware Retrieval	+13.89	[0.00, 33.33]	0.250	-39.09%	[-519, 12]	0.774

发现实验为 Body-aware 提供了较强的成功率证据。确认实验的改善方向相同，但成功率区间下界为 0，任务级 p=0.250，episode 级精确 McNemar 检验 p=0.0625。按照常用的 0.05 阈值，确认实验没有单独完成统计确认。

确认实验中，Body-aware 的任务聚类 Token 区间为负 518,502 至正 12,435，跨过 0。12 道题中 5 道更省、7 道更费，任务级符号检验 p=0.774。总体均值下降由少数高开销任务贡献，不能解释成多数任务上的固定节省。

四 检索和失败分析

表 7　检索命中与失败结果

实验和方法	Gold Hit at 3	命中时成功率	漏检时成功率	失败 episodes	动作预算耗尽
发现实验 对外报告 v9 Flat Retrieval	66.67%	87.50%	50.00%	9	7
发现实验 对外报告 v9 Body-aware Retrieval	83.33%	93.33%	66.67%	4	2
独立确认实验 v10 Flat Retrieval	66.67%	100.00%	83.33%	2	2
独立确认实验 v10 Body-aware Retrieval	75.00%	92.59%	100.00%	2	2

发现实验中，Body-aware 的 Gold Hit at 3 为 83.33%，Flat 为 66.67%。确认实验中的差距缩小为 75.00% 对 66.67%。确认实验里，Body-aware 漏检时反而全部成功，说明 Gold Skill 排名不能单独解释结果，Top 3 中其他 Skill 和后续执行路径同样会改变成败。

确认实验共有 11 次失败，其中 10 次耗尽环境动作预算。No Skill 失败 7 次，Flat 和 Body-aware 各失败 2 次。检索条件减少了长轨迹失败，但 melt v025 在两种检索条件下仍各失败 2 次，Skill 并没有消除所有执行问题。

五 结果解释

固定 Skill 检索的效果可以重复

Body-aware 在两批互不重叠的任务上都比 No Skill 获得更高成功率和更低总体成本。确认实验中 Flat 也达到相同成功率，说明有效信号不只来自读取完整正文；在当前任务上，加载一组相关 Skill 本身可能已经减少无效探索。

Body-aware 相对 Flat 的优势不稳定

发现实验中，Body-aware 的成功率和成本都优于 Flat。确认实验中两者成功率持平，只保留了总体成本优势。因此，现有证据支持继续研究正文感知检索，但不足以写成 Body-aware 在不同任务集上稳定优于 Flat。

平均 Token 需要结合任务分布解释

长轨迹任务会累计大量上下文，少数失败 episode 可以显著抬高平均 Input Tokens。发现实验和确认实验都出现这种右偏分布。报告保留总体均值，因为它反映实际推理支出；任务级区间和方向计数用于说明该均值是否由多数任务共同产生。

六 研究限制

- 两批实验共有 24 道独立 variation，但都来自相同六类 ScienceWorld 任务。结果不能外推到全部 ScienceWorld 或其他交互环境。
- Skill v3 在更早的任务上经过人工修订。确认题没有参与修订，但仍与开发题属于相邻任务族。
- hash-embedding-v1 是确定性本地检索基线，不代表预训练语义 embedding 或训练式 Router。
- API 请求名称和 temperature 被记录，服务端模型权重无法由客户端冻结。重复运行仍可能发生波动。
- 确认实验只包含 12 道独立任务。置信区间较宽，显著性结果对少量任务变化敏感。

七 结论

ScienceWorld v9 报告中的发现实验表明，Body-aware Retrieval 可以同时提高成功率并降低推理成本。v10 独立确认实验在新题上重复了相同方向：Body-aware 比 No Skill 高 13.89 个百分点，平均 Total Tokens 低 39.09%。确认实验的任务级统计证据不足，Flat 又取得相同成功率，因此不能据此声称正文感知检索已经稳定优于轻量检索。

当前最稳妥的结论是：固定 Skill 检索能在这组 ScienceWorld 长流程任务中减少失败和总体推理开销；Body-aware 是否具有独立且可迁移的优势，还需要更多预先固定的任务或其他环境验证。

八 复现信息

表 8　冻结数据和内部编号

对外名称	内部运行编号	记录数	冻结文件 SHA 256
ScienceWorld v9 发现实验报告	scienceworld-v6-router-formal-12x3	180	c978ce0568f89fecaff48848327817cdd3493a18162df1bc0b99bcdaf9b043fd
ScienceWorld v10 独立确认实验	scienceworld-v10-confirm-12x3	108	d6614857fe39458c0e8f23e04c96d75d15d6b7f9cb90c131f0a391b6cfd9a4e2

对外版本号用于区分报告和确认阶段。内部运行编号、目录名和哈希用于复现，保留原值，不作追溯性重命名。

参考资料

1　Wang R　Jansen P　Cote M A　Ammanabrolu P　ScienceWorld Is your Agent Smarter than a 5th Grader　Proceedings of EMNLP 2022　11279 至 11298　DOI 10.18653/v1/2022.emnlp-main.775